

Kostenkalkulation

2.1 Annahmen zur Nutzung (4 Wochen Test, 20 Arbeitstage)

Chat-Nutzung (GPT-5.1 mini):

- **60 ausführliche Fragen pro Tag**
- **20 Arbeitstage**
→ **1.200 Fragen** insgesamt

Pro Frage (konservativ nach oben):

- **Ø 1.800 Input-Tokens** (Prompt + Kontext aus RAG)
- **Ø 900 Output-Tokens**

Token-Gesamtmenngen:

- **Input gesamt:**
 $1.200 \text{ Fragen} \times 1.800 \text{ Tokens} = \mathbf{2.160.000 \text{ Input-Tokens}}$
- **Output gesamt:**
 $1.200 \times 900 = \mathbf{1.080.000 \text{ Output-Tokens}}$

Prompt-Caching (Kontext & Systemprompt wiederholen sich):

- **70 %** der Input-Tokens als „normale“ Input-Tokens
- **30 %** als **Cached Input**

Also:

- **Uncached Input:** 70 % von 2.160.000 = **1.512.000 Tokens**
- **Cached Input:** 30 % von 2.160.000 = **648.000 Tokens**

Dokumentenbasis / Embeddings:

Für den Testzeitraum nehmen wir **relativ viele Dokumente**, damit wir kostenmäßig eher oben landen:

- **500 Dokumente** initial (Richtlinien, Vorlagen, Wissensartikel)
 - Ø 1.500 Tokens pro Dokument
→ $500 \times 1.500 = \mathbf{750.000 \text{ Tokens}}$
- **50 Updates / neue Dokumente** im Zeitraum
 - Ø 1.000 Tokens
→ $50 \times 1.000 = \mathbf{50.000 \text{ Tokens}}$

Embedding-Tokens gesamt:

$750.000 + 50.000 = \mathbf{800.000 \text{ Tokens}}$

Umrechnung in 1.000er-Blöcke:
 $800.000 / 1.000 = \mathbf{800 \text{ Einheiten}}$ à 1.000 Tokens.

OCR-Nutzung (Mistral OCR):

- **800 Seiten** gescannte PDFs (z.B. gescannte Akten, alte Verträge, etc.) in 4 Wochen
 - Preis: \$1 / 1.000 Seiten → 800 Seiten = $0,8 \times \$1 = \mathbf{\$0,80}$
-

2.2 Kostenberechnung im Detail

2.2.1 GPT-5.1 mini (Azure – Sweden Data Zone)

a) Uncached Input

- Tokens: **1.512.000**
- Preis: **\$0,28 / 1.000.000 Tokens**

Kosten:

$1.512.000 / 1.000.000 = 1,512 \text{ Mio}$
→ $1,512 \times \$0,28 = \mathbf{\$0,42336} \approx \mathbf{\$0,42}$

b) Cached Input

- Tokens: **648.000**
- Preis: **\$0,03 / 1.000.000 Tokens**

Kosten:

$0,648 \text{ Mio} \times \$0,03 = \mathbf{\$0,01944} \approx \mathbf{\$0,02}$

c) Output

- Tokens: **1.080.000**
- Preis: **\$2,20 / 1.000.000 Tokens**

Kosten:

$1,08 \text{ Mio} \times \$2,20 = \mathbf{\$2,376} \approx \mathbf{\$2,38}$

d) Summe GPT-5.1 mini (4 Wochen, 1 Mitarbeiter)

- Uncached Input: $\sim \mathbf{\$0,42}$
- Cached Input: $\sim \mathbf{\$0,02}$

- Output: ~ \$2,38

👉 **Summe GPT-5.1 mini: \$2,82** (gerundet)

2.2.2 Embeddings (Azure OpenAI – text-embedding-3-small)

- Tokens: **800.000**
- Abrechnungseinheit: 1.000 Tokens
→ $800.000 / 1.000 = 800$ Einheiten
- Preis (konservativ): **\$0,000025 / 1.000 Tokens**

Kosten:

$$800 \times \$0,000025 = \$0,02$$

👉 **Embedding-Kosten gesamt (4 Wochen): ~ \$0,02**

2.2.3 Mistral OCR

- Seiten: **800**
- Preis: **\$1,00 / 1.000 Seiten**

Kosten:

$$800 / 1.000 \times \$1 = \$0,80$$

👉 **OCR-Kosten gesamt (4 Wochen): \$0,80**

2.3 Gesamtkosten pro Mitarbeiter (4 Wochen)

Jetzt alles zusammen:

Komponente	Kosten (4 Wochen, 1 Mitarbeiter)
GPT-5.1 mini (Chat)	~ \$2,82
Embeddings	~ \$0,02
Mistral OCR	~ \$0,80
Summe	~ \$3,64