

Kostenkalkulation Testphase

1. Rahmen & Annahmen (pro Monat, pro Mitarbeiter)

Zeitraum: ca. 4 Wochen / 20 Arbeitstage

Nutzung: 1 Mitarbeiter im Pilot

1.1 Chat-Nutzung (GPT-4.1 mini, Azure)

- **60 Anfragen pro Tag**
- **20 Arbeitstage**
→ **1.200 Anfragen pro Monat**

Pro Anfrage rechnen wir großzügig mit:

- **1.800 Tokens Eingabe (Input)**
- **900 Tokens Ausgabe (Output)**

Damit ergeben sich:

- **Gesamter Input:**
 $1.200 \times 1.800 = 2.160.000$ Tokens
- **Gesamter Output:**
 $1.200 \times 900 = 1.080.000$ Tokens

1.2 Aufteilung: Uncached vs. Cached Input

Wir unterstellen:

- **70 % Uncached Input** → 1.512.000 Tokens
- **30 % Cached Input** → 648.000 Tokens

Kurz erklärt für den Kunden:

- **Uncached Input**
= „neuer“ Inhalt, den das Modell so noch nicht gesehen hat (neue Fragen, neue Kontextpassagen).
→ wird zum normalen Input-Preis abgerechnet.
- **Cached Input**
= wiederkehrende Teile, z. B. fixer Kanzlei-Systemprompt, Standard-Anweisungen, sich wiederholende Kontexte.
→ Azure/OpenAI erkennt diese Wiederverwendung und berechnet sie stark rabattiert.

Die Annahme „30 % cached“ ist **realistisch und eher vorsichtig**, d. h. lieber etwas zu viel Kosten einkalkuliert als zu wenig.

1.3 Embeddings (Dokumenten-Vektorisierung)

Für die interne Wissensbasis (RAG) rechnen wir:

- ca. **800.000 Tokens** pro Monat, z. B.:
 - 500 Dokumente à 1.500 Tokens = 750.000 Tokens
 - 50 neue/aktualisierte Dokumente à 1.000 Tokens = 50.000 Tokens

→ **Summe Embedding-Tokens: 800.000**

1.4 OCR (Mistral OCR)

Mistral OCR wird nur dort eingesetzt, wo es nötig ist, z. B.:

- gescannte PDFs
- bildlastige Anleitungen mit wichtigen Abbildungen

Annahme:

- **1.000 Seiten pro Monat**, die tatsächlich über OCR laufen.
-

2. Preise (Basis USD)

GPT-4.1 mini (Azure, Region Schweden):

- **Uncached Input:** 0,44 \$ / 1.000.000 Tokens
- **Cached Input:** 0,11 \$ / 1.000.000 Tokens
- **Output:** 1,76 \$ / 1.000.000 Tokens

Embeddings („ada“):

- **0,000121 \$ / 1.000 Tokens**
→ 0,121 \$ / 1.000.000 Tokens

Mistral OCR:

- **1,00 \$ / 1.000 Seiten**

Alle Beträge in USD, Wechselkurs- und Mehrwertsteuer-Effekte kommen ggf. noch hinzu.

3. Kostenrechnung (konservativ nach oben gerundet)

3.1 GPT-4.1 mini (Chat)

Uncached Input

- 1.512.000 Tokens
- $1,512 \text{ Mio} \times 0,44 \$ \approx 0,67 \$$
→ **Planwert: 0,70 \$**

Cached Input

- 648.000 Tokens
- $0,648 \text{ Mio} \times 0,11 \$ \approx 0,07 \$$
→ **Planwert: 0,10 \$**

Output

- 1.080.000 Tokens
- $1,08 \text{ Mio} \times 1,76 \$ \approx 1,90 \$$
→ **Planwert: 2,10 \$**

Geplante Chat-Kosten GPT-4.1 mini (1 Monat, 1 Mitarbeiter):
 $\approx 2,90 \$$

3.2 Embeddings (Dokumentenbasis)

- 800.000 Tokens
- $800 \times 0,000121 \$ = 0,0968 \$$
→ **Planwert: 0,12 \$**

Geplante Embedding-Kosten (1 Monat, 1 Mitarbeiter):
 $\approx 0,12 \$$

3.3 Mistral OCR

- 1.000 Seiten
- $1.000 / 1.000 \times 1,00 \$ = 1,00 \$$ (exakt)

Wir setzen einen kleinen Puffer an:

→ **Planwert: 1,20 \$**

Geplante OCR-Kosten (1 Monat, 1 Mitarbeiter):
 $\approx 1,20 \$$

4. Gesamtkosten (Pilot pro Mitarbeiter und Monat)

Pro Mitarbeiter, pro Monat (4 Wochen):

- GPT-4.1 mini (Chat): **$\approx 2,90$ \$**
- Embeddings (Dokumenten-Vektorisierung): **$\approx 0,12$ \$**
- Mistral OCR (1.000 Seiten): **$\approx 1,20$ \$**

Gesamt (konservativ, inkl. Puffer)

$\approx 4,20$ \$ pro Mitarbeiter und Monat

= 210\$ pro Monat bei 50 Mitarbeitereitern.